

PREVISÃO DA QUALIDADE DE VINHOS USANDO MACHINE LEARNING:

Análise Comparativa de Modelos de Classificação com
Feature Engineering

Grupo 176:

Marília Aparecida da Silva Lima

Fernando Rosa Salles

Guilherme Alfredo Palitos Alves



Data Analytics - Fiap
Tech Challenge

Sumário

Introdução	2
Definição do problema	2
Objetivo Geral	3
Análise Exploratória dos Dados	4
Distribuição das variáveis	4
Análise de correlações	7
Detecção de outliers e duplicatas	8
Balanceamento de classes	9
Pré-processamento de Dados	10
Feature Engineering	10
Escalonamento	11
Estratégia de balanceamento	11
Desenvolvimento de modelos	12
Modelos Seleccionados	12
Métricas de avaliação	12
Resultados e discussão	14
Resultados dos Top 3 modelos	14
Análise de desempenho	14
Discussão sobre o Trade-off entre os modelos	18
Importância das variáveis	19
Implicações para o processo de produção:	20
Conclusão	22
Referencias	23

Introdução

A avaliação da qualidade do vinho está constantemente fazendo parte do processo de certificação, podendo ser aplicada para a melhoria na produção de vinho (identificar os fatores mais influentes), para acamar estratificar vinhos, como marcas premium, sendo útil para a determinação dos preços (Cortez *et al.*, 2009).

A indústria vinícola busca constantemente otimizar seus processos de produção para garantir a qualidade final do produto. Tradicionalmente, a avaliação da qualidade é feita por sommeliers profissionais através de análise sensorial, um processo subjetivo, demorado e custoso. Neste contexto, com o avanço das técnicas da ciência de dados, que permitem prever a qualidade do vinho utilizando as características físico-químicas de forma objetiva escalável e consistente.

Portanto, a certificação dos vinhos é um conjunto de avaliações por testes sensoriais e físico-químicos, os testes físico-químicos para caracterizar o vinho são determinados pela densidade, valores de pH e/ou teor alcoólico, ao passo que os teste sensoriais são determinados principalmente por especialista humanos. Cortez *et al.* (2009) ressalta que o paladar humano é o sentido menos compreendido, pois varia de pessoa para pessoa, assim, a classificação do vinho pode ser uma tarefa difícil.

O presente projeto tem como objetivo desenvolver um pipeline completo com análise e modelagem preditiva de um conjunto de dados relacionados às variáveis do vinho tinto português. O *dataset* utiliza o Wine Quality, contendo N amostras de vinhos com 11 características físico-químicas (como teor alcoólico, acidez volátil, pH, sulfatos, entre outras) e uma nota de qualidade atribuída por especialistas (de 0 a 10).


Definição do problema

O problema foi formulado como uma tarefa de classificação binária supervisionada, onde precisa desenvolver um modelo de classificação binária capaz de prever se um vinho é de alta qualidade (nota ≥ 7) ou de baixa/média qualidade (nota < 7). Essa simplificação permite focar no desafio mais relevante para a indústria: identificar quais vinhos atendem ao padrão de alta qualidade, assim, o modelo visa auxiliar vinícolas na triagem de lotes, redução de custos de análise sensorial e tomada de decisões em tempo real durante a produção.

O *dataset* apresenta um desequilíbrio significativo entre as classes, com aproximadamente 86% dos vinhos classificados como baixa/média qualidade e apenas 13,5% como alta qualidade, como pode ser observado no gráfico 1, o que exige a aplicação de estratégias específicas de balanceamento.

O Gráfico 1 apresenta a análise da variável importante do projeto, composta por duas visualizações diferentes mais complementares. O gráfico de barras à esquerda mostra a distribuição das notas de qualidade que foram atribuídas pelos sommeliers profissionais, que variam de 3 a 8. As barras em roxo claro representam vinhos de baixa/média qualidade (notas inferiores a 7), enquanto as barras em roxo escuro representam vinhos de alta qualidade (notas iguais ou superiores a 7). Observa-se uma concentração nas notas 5 (433 amostras) e 6 (406 amostras), com apenas 137 vinhos atingindo as notas 7 e 8. Essa distribuição assimétrica prova o desbalanceamento natural do *dataset*.

Gráfico 1: Distribuição das classificações do vinho



Nota: O gráfico de barras mostra as notas dos especialistas que podem variar entre 3 e 8, para a qualidade dos vinhos. O gráfico de barras, transformou a variável 'quality' em duas classes: classe 1, vinhos de alta qualidade (nota ≥ 7) e classe 0, vinhos de baixa/média qualidade (nota < 7).

O gráfico de pizza à direita reforça essa análise ao apresentar a classificação binária resultante: 86,5% (881 amostras) dos vinhos são classificados como baixa/média qualidade, enquanto apenas 13,5% (137 mostrar) alcançam alta qualidade. Essa proporção é aproximadamente 6% maior para a classe 0, representando um desafio significativo para o treinamento dos modelos, exigindo a aplicação de técnicas específicas de balanceamento para evitar viés em favor da classe majoritária.

Objetivo Geral

Desenvolver, treinar e avaliar modelos de Machine Learning capazes de prever a qualidade do vinho com base em suas características físico-químicas, criar novas features (se considerado relevante), comparando diferentes algoritmos, estratégias de balanceamento e técnicas de escalonamento para identificar a configuração que apresenta o melhor desempenho na detecção de vinhos de alta qualidade.

Análise Exploratória dos Dados

A primeira etapa consiste em investigar e compreender a distribuição das variáveis, identificar correlação, detectar outliers e analisar o balanceamento das classes.

Distribuição das variáveis

Para analisar a distribuição das variáveis, a tabela 1 apresenta as estatísticas descritivas das 11 variáveis físico-químicas, composta por 1018 amostras após a remoção de dados duplicados (explicado mais a frente), a análise apresenta alguns aspectos interessantes para o pré-processamento dos dados.

Tabela 1: Estatística descritiva

Variáveis	N	Média	Desvio Padrão	Mínimo	Mediana (50%)	Máximo
fixed acidity	1.018	8,289	1,741	4,6	7,9	15,9
volatile acidity	1.018	0,534	0,183	0,12	0,52	1,58
citric acid	1.018	0,269	0,196	0,0	0,25	1,0
residual sugar	1.018	2,524	1,315	0,9	2,2	15,5
chlorides	1.018	0,087	0,049	0,012	0,079	0,611
free sulfur dioxide	1.018	15,649	10,177	1,0	13,0	68,0
total sulfur dioxide	1.018	46,326	33,124	6,0	38,0	289,0
density	1.018	0,99	0,002	0,99	0,997	1,004
pH	1.018	3,312	0,158	2,74	3,31	4,01
sulphates	1.018	0,657	0,168	0,33	0,62	2,0
alcohol	1.018	10,452	1,095	8,4	10,2	14,9

A disparidade de escala é visível, apresentando magnitudes diferentes nas variáveis. Pode-se observar que a variável density apresenta uma variação estreita (0,990 a 1,004, amplitude de apenas 0,014), enquanto a variável total_sulfur_dioxide varia de 6 a 289 (amplitude de 283). Essa diferença de escala poderia distorcer modelos baseados em distância, como KNN (K-Nearest Neighbors) e SVM (Support Vector Machine), reforçando a necessidade de escalonamento das features.

A tabela 1 nos mostra que existe uma presença de Outliers e Assimetria (mede o quanto uma distribuição se desvia da simetria perfeita, ou seja, uma curva em formato de sino). A comparação entre média e mediana, aliada aos valores de assimetria, evidencia distribuições assimétricas em diversas variáveis. A variável 'residual sugar' apresenta assimetria (como podemos ver no gráfico 2), com valor máximo de 15,5g/L enquanto o terceiro quartil (Q3) é apenas 2,6g/L e apresentando uma média (2,524) acima da mediana (2,200). Isso significa que


a grande maioria dos vinhos tem baixo teor de açúcar residual (característica principalmente de vinhos secos), mas existem alguns vinhos doces com valores extremamente altos. Esses vinhos doces são outliers que podem influenciar negativamente modelos sensíveis à escala.

A variável chlorides também apresenta uma assimetria significativa, a maioria dos vinhos possui baixo teor de média (0,087 g/L), mas existem amostras com valores até 7 vezes maiores (máximo 0,611 g/L). Essa característica reforça a importância do *RobustScaler*, pois o *StandardScaler* seria completamente distorcido por esses valores extremos.

As variáveis density e pH, apresentam distribuições mais simétricas como pode ser visto no gráfico 2 e tabela 1, com uma média e mediana próximas, indicando menor influência de outliers.

O Gráfico 2 apresenta histograma para cada uma das 11 variáveis físico-química dos vinhos, complementando a análise numérica da Tabela 1. A visualização confirma os padrões identificados nas estatísticas descritivas, que revelava a assimétrica da maioria das variáveis.

Gráfico 2: Histogramas gerais: distribuição das características Físico-Química



Nota: Distribuição das 11 características físico-químicas dos vinhos. Observa-se assimetria positiva em variáveis como chlorides, residual sugar e total sulfur dioxide.


Os histogramas das variáveis chlorides, residual sugar e sulphates apresentam uma distribuição altamente assimétricas à direita (positiva), boa parte dos dados se concentram em valores mais baixos, estendendo-se a uma cauda longa para valores altos, essa visualização está de acordo com a tabela 1.

O histograma do chlorides mostra que aproximadamente 95% dos vinhos possuem cloreto abaixo de 0,15 g/L, mas existem poucos vinhos com valores excessivamente altos (até 0,611 g/L). No entanto, o histograma do residual sugar mostra que a maioria dos vinhos é seco (teor de açúcar residual entre 1,9 e 2,6 g/L), mas existe alguns vinhos doces com até 15,5 g/L, essa cauda longa explica por que a média é maior que a mediana. O histograma de sulphates, mostra que alguns vinhos têm até 2,0 g/L, mas a maioria se concentra entre 0,55 e 0,72 g/L.

Em contraste, as variáveis density, e pH, apresentam histogramas com formato mais próximo da simetria, onde a média e a mediana são quase idênticas (density: 0,997 vs. 0,997; pH: 3,312 vs. 3,310), ou seja, estão mais próximas de uma distribuição normal. A análise conjunta da Tabela 1 e gráfico 2 mostra uma consistência entre as estatísticas numéricas e as distribuições visuais. As variáveis com maior assimetria na tabela (chlorides, residual sugar, sulphates) correspondem aos histogramas com cauda longa à direita, enquanto as variáveis com assimetria próxima de zero (density, pH) apresentam distribuições visualmente simétricas.

O Gráfico 2 mostra a distribuição de todas as features dos dados, e se separar por classe, quais características físico-química diferenciam vinhos bons de ruins? O Gráfico 3 apresenta a distribuição das características físico-químicas separadas por classes de qualidade (alta qualidade representada pelo roxo escuro vs. baixa/média qualidade em roxo claro).

Gráfico 3: Distribuição de características: Vinhos de alta Qualidade vs. Vinhos de baixa/média qualidade



Nota: Comparação da distribuição das características físico-químicas entre vinhos de alta qualidade (roxo escuro) e baixa/média qualidade (roxo claro). Variáveis como alcohol e volatile acidity apresentam maior poder discriminante entre as classes.

Observa-se um padrão importante, algumas variáveis têm um forte poder discriminatório, vinhos de alta qualidade têm uma concentração em teores alcoólicos mais elevados (entre 10-14%), enquanto vinhos de baixo-média qualidade apresentam teores mais baixos (entre 9-11%), apontado no histograma da variável alcohol. O histograma da variável volatile acidity, mostra que vinhos de alta qualidade tem menor acidez volátil, concentrados entre 0,3-0,6, enquanto vinhos de baixa-média qualidade apresentam valores mais altos (0,4-0,6). Pode-se também observar que vinhos de alta qualidade tendem a ter sulfatos mais elevados (0,6-0,9), enquanto vinhos de baixa/média qualidade concentram-se em valores menores, entre 0,5-0,7 (variável sulphates).


Observa-se que as variáveis citric acid e density tem um poder discriminatório moderado, vinhos de alta qualidade apresentam maior concentração de ácido cítrico (0,3-0,6) comparados

aos de baixa qualidade (0,1-0,4) e Vinhos de alta qualidade possuem densidade ligeiramente menor (0,994-0,998) que vinhos de baixa qualidade (0,996-1,000). fixed acidity, ‘residual sugar’, chlorides, free sulfur dioxide, total sulfúrfur dioxide e pH, têm pouco poder discriminatório, indicando que essas variáveis isoladamente têm menos capacidade de separar vinhos bons de vinhos ruins.

Análise de correlações

A Gráfico 4 apresenta a matriz de correlação entre as 11 variáveis físico-químicas e a variável alvo (quality). O heatmap utiliza uma escala de cores onde tons de roxo escuro indicam correlação positiva forte, tons de roxo claro indicam correlação negativa forte, e tons próximos do branco indicam correlação próxima de zero, ou seja, ausência de relação linear.

Gráfico 4: Matriz de correlação entre Features



Nota: Matriz de correlação de Pearson entre as variáveis físico-químicas e a qualidade do vinho. Tons de roxo escuro indicam correlação positiva; tons de roxo claro indicam correlação negativa. Mas correlação ≠ causalidade! Duas variáveis podem estar correlacionadas sem uma causar a outra.

A matriz de correlação revela que as variáveis alcohol (vinhos com maior teor alcoólico tendem a ser mais bem avaliados) com 0.49, sulphates (atuam como conservantes e antioxidantes naturais) com 0.26 e citric acid (está associado ao frescor e equilíbrio do sabor) com 0,24, têm correlação positiva com a qualidade (quality). Entretanto, as variáveis volatile acidity (alta acidez volátil está associada a vinhos de baixa qualidade) com 0,41, density (densidade mais elevada está associada a vinhos de menor qualidade) com 0,19 e chlorides (teor

elevado de cloretos pode indicar excesso de salinidade, o que é indesejável em vinhos de qualidade) com 0,12, apresentam uma correlação negativa com a qualidade do vinho.


Além das correlações com a variável alvo (quality), o mapa revela outras relações importantes entre as próprias features, como a correlação positiva entre fixed acidity e citric acid com 0,67, apresentando uma forte correlação, indicando que vinhos com maior acidez fixa tendem a ter mais ácido cítrico. As variáveis fixed acidity e 'pH', apresentam uma forte relação negativa (-0,69), como esperado quimicamente, maior acidez significa menor pH. E as variáveis density e alcohol, apresentam uma relação negativa moderada (-0,50), pois o álcool é menos denso que a água, assim, vinhos que apresentam maior teor alcoólico tendem a ser menos densos.

Em suma, as variáveis que apresentam maior correlação com a variável alvo são alcohol, sulphates, citric acid e volatile acidity. Entretanto, nenhuma variável isoladamente apresenta correlação muito forte ($>0,7$) com a quality, o que justifica a necessidade de modelos que capturem interações entre as múltiplas variáveis, e não depender de uma única feature.

Detecção de outliers e duplicatas

O Gráfico 5, apresenta os boxplots das 11 variáveis, evidenciam a presença de outliers em diversas variáveis, especialmente em chlorides, total sulfur dioxide e residual sugar (pontinhos fora dos bigodes), apresentando valores muito distantes da maioria dos dados, isso é comum em dados reais.

Gráfico 5: Detectando outliers



Nota: Boxplots das variáveis físico-químicas para detecção de outliers (pontos fora dos bigodes). Destacam-se outliers em chlorides, total sulfur dioxide e residual sugar.

Ao invés de remover os outliers, o que iria fazer perder informações valiosas, será tratado na normalização, no processo de pré-processamento.

Durante a análise exploratória, foram identificadas 125 observações duplicadas, a remoção dessas duplicadas foi uma decisão técnica criteriosa, baseada em dois importantes pontos: O primeiro é o risco de *Data Leakage*, podendo resultar em vazamento de informações entre o conjunto de treino e de teste, caso uma duplicada fosse para o treino e outra para o teste, assim, o modelo estaria testando dados idênticos aos que já havia visto no treinamento. Segundo seria a probabilidade estatística, a probabilidade de dois vinhos distintos apresentarem exatamente os mesmos valores em todas as 11 variáveis físico-química é extremamente baixa,

portanto, as duplicatas podem corresponder a erro de medição, registro ou replicação acidental do dataset. É um trade-off aceitável, para garantir a integridade dos dados e prevenção de vies nas avaliações.

Balanceamento de classes

A variável alvo (`quality_binary`) apresenta desbalanceamento significativo, como pode ser observado no Gráfico 1, apenas 13,5% das amostras são de alta qualidade. Para mitigar esse problema, foram testadas três estratégias de balanceamento: SMOTE (*oversampling* sintético), *class_weight* (ponderação de classes) e a combinação de ambas."

Pré-processamento de Dados

Os dados foram divididos em treino (80%) com 814 amostras e teste (20%) com 204 amostras, utilizando a função *train_test_split*, utilizando o parâmetro *stratify=y*, para manter a proporção das classes. Essa estratificação evita que a divisão aleatória resulte em conjuntos desbalanceados, o que poderia prejudicar o treinamento e a avaliação dos modelos.

Essa proporção entre 80/20 foi escolhida por representar um equilíbrio, suficiente para treinar, capturando padrões complexos e não lineares das variáveis, e suficiente para uma avaliação confiável. É adequada para datasets de tamanho moderado (aproximadamente 1000 amostras).

Feature Engineering

Com base na análise de correlações, foram criados três features para capturar as interações não-lineares entre as variáveis:

- **alcohol_volatile_ratio (Razão Álcool/Acidez Volátil):** Calculado como $\text{alcohol} / \text{volatile_acidity}$, captura o equilíbrio entre os dois fatores mais influentes na qualidade do vinho. O álcool com uma relação positiva (0,49) e a acidez volátil com uma relação negativa (0,41). Essa feature sintetiza um trade-off entre qualidade (álcool) e o defeito (acidez volátil).
- **sulphates_alcohol_product (Interação Sulfatos-Álcool):** Calculada como $\text{sulphates} \times \text{alcohol}$, captura a interação entre dois fatores positivos. Os sulfatos atuam como conservantes naturais (0,26), enquanto o álcool contribui para o corpo e estrutura do vinho (0,49). O produto entre essas variáveis representa vinhos que combinam boa conservação com estrutura alcoólica adequada.
- **acidity_balance (Balanço de Acidez):** Calculada como $\text{citric_acid} - \text{volatile_acidity}$, diferença entre ácido cítrico e acidez volátil. O ácido cítrico está associado ao frescor e equilíbrio do sabor (com correlação positiva de 0,24), enquanto a acidez volátil elevada indica oxidação ou contaminação (com correlação negativa de 0,41). Valores positivos indicam predominância de acidez benéfica, enquanto valores negativos sugerem defeitos no vinho.

Essas features fazem sentido, pois a acidez volátil elevada é um defeito irreversível causado pela oxidação do etanol em ácido acético (vinagre), não é possível retirar o ácido acético da bebida depois que ele se forma. Enquanto o álcool e os sulfatos (evitam que o líquido seja contaminado por bactérias indesejadas e protegem a bebida contra o oxigênio) são indicadores de fermentação completa e boa conservação.

Para avaliar o impacto da seleção de variáveis no desempenho dos modelos, foram definidos dois cenários:

1. **Features Originais (11 variáveis):** todas as variáveis do *dataset* original;
2. **Com Engenharia (14 variáveis):** features originais + as 3 novas features criadas.
3. **Features mais correlacionadas (5 variáveis):** top 5 variáveis correlacionadas com a qualidade (alcohol, volatile acidity, sulphates, citric acid e density)

A comparação entre os três cenários permite verificar se o *feature engineering* contribuiu efetivamente para a performance ou se introduziu ruído e redundância, fornecendo evidências empíricas sobre a utilidade das novas variáveis criadas.

Escalonamento

O escalonamento das variáveis é uma etapa importante, pois modelos baseados em distância ou em gradientes, são sensíveis à magnitude das features. Foram testados dois escalonamentos:

- **StandardScaler:** padroniza as features subtraindo a média e dividindo pelo desvio padrão, resultando em distribuição com média igual a zero e desvio padrão igual a um. Porém, é um método sensível a outliers, pois a média e o desvio padrão pode ser significativamente distorcidas por valores extremos;
- **RobustScaler:** padroniza as features subtraindo a mediana e dividindo pelo intervalo interquartil (IQR - diferença entre o terceiro e o primeiro quartil). Como a mediana e o IQR são estatísticas robustas (não influenciadas por valores que fogem do comum), esse escalonador é mais adequado para *datasets* com outliers.

Como foi citado na seção de análise exploratória dos dados, existe uma presença significativa de outliers, justificando a preferência de *RobustScaler* na configuração final dos modelos.

Estratégia de balanceamento

Para solucionar o desbalanceamento do *dataset*, foram testadas três estratégias distintas:

- **SMOTE (*Synthetic Minority Over-sampling Technique*):** gera amostras sintéticas da classe minoritária (alta qualidade), intercalando os vizinhos mais próximos, modificando fisicamente o *dataset*.
- **Class_Weight = 'balanced':** atribui pesos maiores aos erros cometidos na classe minoritária durante o tratamento, sem modificar os dados originais.
- **SMOTE + Class_Weight = 'balanced':** combina ambas as abordagens, oferecendo dupla proteção contra o desbalanceamento.

Todas as estratégias foram implementadas dentro do Pipeline, para garantir que as amostras sintéticas feitas pelo SMOTE ocorram apenas nos dados de treino, evitando o vazamento de dados (*Data Leakage*) e garantindo que as métricas refletem os modelos de dados não vistos.

É importante destacar que tanto o SMOTE quanto o `Class_Weight = 'balanced'` foram restritos estritamente ao conjunto de treino. Pois o SMOTE altera a distribuição dos dados, e o `Class_Weight = 'balanced'` altera a função de custo. Em nenhum momento o conjunto de testes é modificado, pois deve representar o cenário do mundo real. Gerar dados sintéticos no conjunto de teste, é configurado como vazamento de dados, pois o modelo estaria sendo avaliado em um conjunto artificialmente balanceado, mascarando sua real capacidade.

Também é importante enfatizar que a padronização das variáveis (escalonamento) foi realizada antes de aplicar o SMOTE, pois essa estratégia utiliza o algoritmo KNN (*K-Nearest Neighbors*) para localizar os vizinhos detectar mais próximos e criar amostras, dependendo do cálculo de distância euclidianas. Se fosse aplicado antes do escalonamento, variáveis com magnitudes maiores dominariam o cálculo de distância em relação às variáveis menores.

Desenvolvimento de modelos

Modelos Selecionados

Foram selecionados seis algoritmos de classificação, que abrangem diferentes abordagens de aprendizado. Entre eles tem modelos baseados em Árvores (*Random Forest*, *XGBoost* e *Gradient Boosting*), modelos baseados em distância (KNN e SVM) e modelo linear (Regressão Logística):

- **Random Forest:** combina múltiplas árvores de decisão, oferecendo robustez a outliers;
- **Gradient Boosting:** algoritmo sequencial que constrói árvores para corrigir erros das anteriores, capturando padrões complexos;
- **XGBoost:** execução otimizada de *Gradient Boosting*, apresentando alta performance em dados tabulares;
- **KNN (*K-Nearest Neighbors*):** classificação baseada em vizinhos mais próximos, sensível a outliers;
- **SVM (*Support Vector Machine*):** máquina de vetores de suporte, capaz de lidar com relações não-lineares;
- **Regressão Logística:** modelo linear probabilístico.

Essa diversidade permite avaliar diferentes modelos de aprendizagem e identificar qual abordagem é mais adequada.

Otimização de hiperparâmetros e validação cruzada

Cada um desses modelos possui hiperparâmetros, que seriam configurações definidas antes do treinamento para controlar o comportamento do algoritmo, e devem ser ajustados empiricamente, o que diferencia os parâmetros internos. Para encontrar a melhor configuração de cada modelo, foi utilizado o **RandomizedSearchCV**, que testa combinações aleatórias dentro de ranges pré-definidos.

Como será testado múltiplas combinações de cenários, escalonamento e estratégia de balanceamento foi escolhido a abordagem **RandomizedSearchCV** ao invés de **GridSearchCV**.

Para garantir a robustez e evitar overfitting, foi utilizada validação cruzada com 3 folds (*StratifiedKfold*), dividindo o conjunto de treino em 3 subconjuntos (“dobras”) de tamanhos aproximadamente iguais, e mantendo a proporção de classes da amostra original. Essa estratégia é particularmente importante devido ao desbalanceamento da base. Sem a estratificação, alguns folds poderiam não ter exemplos da classe minoritária (vinhos de alta qualidade), isso iria comprometer a avaliação.

Métricas de avaliação

Os desempenhos dos modelos selecionados foram avaliados utilizando múltiplas métricas, cada uma capturando diferentes aspectos:

- **F1-Score:** essa é a métrica principal, usa a média harmônica entre *Precision* e *Recall*, equilibrando as duas métricas, é adequada para *datasets* que apresentam dados desbalanceados;
- **Acurácia:** proporção de previsões corretas (tanto positivas quanto negativas) em relação ao total. É uma métrica intuitiva, porém pode enganar, principalmente em *datasets* desbalanceados;
- **AUC-ROC (*Area Under the Receiver Operating Characteristic Curve*):** mede a capacidade dos modelos de identificar as classes em diferentes *thresholds* de decisões.

Valores próximos de 1, indica que o modelo consegue separar as classes, e se for próximo de 0,5, o modelo é inútil para separar;

- **Precision:** proporção de verdadeiros positivos em relação a todos os positivos previstos, ou seja, mede a qualidade das respostas do modelo;
- **Recall (sensibilidade):** proporção de verdadeiros positivos em relação a todos os positivos reais, ou seja, mede a quantidade de casos reais que o modelo conseguiu encontrar.

Foi utilizado conjuntamente, todas essas métricas para ter uma análise abrangente do desempenho dos modelos.


O F1-Score foi escolhido como métrica principal, pelo fato de os dados estarem desbalanceados, pois a métrica equilibra *Precision* e *Recall*, para que o modelo não apenas ‘chute’ a classe majoritária, diferente da acurácia, que calcula o total de acertos do modelo, tanto para alta qualidade, quanto para baixa/média qualidade. Usamos a AUC-ROC como métrica secundária para validar que o modelo tem boa capacidade discriminativa geral."

Resultados e discussão

Foram testados 6 algoritmos de classificação: Random Forest, KNN, Regressão Logística, SVM, XGBoost e Gradient Boosting. Para cada modelo foi realizado a otimização de hiperparâmetros através do `RandomizedSearchCV`¹, com validação cruzada de 3 *folds* (*StratifiedKfold*), utilizando o F1-Score como métrica de otimização.

O Gráfico 6 mostra o F1-Score médio dos 6 modelos selecionados para cada cenário (originais, com engenharia e top 5 correlacionadas). Observando o cenário com as top 5 variáveis correlacionadas, destaca-se o Gradient Boosting com $F1=0,592$, entretanto, o cenário das features originais, o Random Forest obteve o melhor desempenho com $F1=0,580$. No entanto, o cenário com engenharias, o desempenho dos modelos é mais homogêneo, com F1-Scores variando entre 0,522 e 0,556.

Gráfico 6: F1- Score médio por modelo em cada cenário



Essa análise preliminar revela que não existe um modelo que seja consistentemente superior em todos os cenários, ou seja, a escolha do melhor algoritmo depende do contexto de features. A adição de novas features não significa que houve uma melhoria consistente de desempenho, apontando que as 11 variáveis originais já capturam informações suficientes. O cenário do Top 5 correlacionada mostrou resultados bons para alguns modelos, indicando que a redução da proporção pode ser viável sem perdas significativas.

O script completo com todas as 108 combinações testadas (6 modelos x 3 estratégias x 2 escaladores) está disponível no notebook anexado. A seguir, apresentamos uma análise mais detalhada dos 3 modelos com melhor desempenho, considerando todas as combinações de cenários, estratégias de balanceamento e escaladores.

O script completo com todos os 6 modelos, cenários, escaladores e estratégias está disponível no notebook. A seguir, apresentamos os resultados dos 3 modelos com maior desempenho.

Resultados dos Top 3 modelos

Análise de desempenho

Os 3 modelos com maior desempenho foram os XGBoost, Gradient Boosting e SVM. Como pode ser observado na tabela 2, XGBoost foi o melhor modelo em F1-score (0,639), mas

¹ Como análise complementar, também foi realizado um teste com `GridSearchCV`, que apresentou resultados similares (RF: $F1=0,640$ vs. XGBoost: $F1=0,639$). A diferença de 0,001 é estatisticamente insignificante, como vai ser mostrado no decorrer do projeto.

o Random Forest teve a melhor acurácia (0,917). O SVM ficou em 3º, mas apresentou um desempenho consistente.

Tabela 2: Top 3 algoritmos com melhor desempenho

Modelo	Cenário	Escalonador	Estratégia	F1-score	Acurácia	Precision	Recall	AUC-ROC
XGBoost	Com engenharias (14)	StandardScaler	SMOTE + <i>class_weight</i>	0.639	0.873	0.511	0.852	0.903
Random Forest	Com engenharias (14)	StandardScaler	<i>class_weight</i>	0.622	0.917	0.778	0.519	0.900
SVM	Originais (11)	RobustScaler	SMOTE	0.594	0.873	0.514	0.704	0.908

Nota: A tabela mostra os 3 modelos com melhor desempenho entre todas as combinações testadas. É importante ressaltar que, para modelos baseados em árvores (XGBoost e Random Forest), tanto o StandardScaler quanto o RobustScaler apresentaram desempenho muito similar. Era esperado, pois algoritmos baseados em árvores não são sensíveis à escala das features, já que realizam divisões baseadas em thresholds ao invés de cálculos de distância. O StandardScaler foi selecionado por apresentar margem ligeiramente superior entre os dois, embora ambos os escalonadores sejam tecnicamente válidos para esses modelos. Entretanto o modelo SVM que é sensível a outliers se beneficiou do RobustScaler, mostrando a importância do escalonamento.

A tabela 2 mostra que o XGBoost alcançou o melhor F1Score (0,639) entre todos os modelos testados, sua melhor combinação foi Features Com Engenharia (14 variáveis), StandardScaler e a combinação SMOTE + *class_weight*. Esse modelo se beneficiou tanto na criação de amostras sintéticas (SMOTE) quanto na penalização de erros na classe minoritária (*class_weight*), resultando em um modelo equilibrado, que encontrou 85,2% dos vinhos bons (Recall) com precisão de 51,1%.


Random Forest apresenta a maior acurácia geral (91,7%), entretanto, apresenta um F1-Score (0,622) inferior ao XGBoost, se destacando também no cenário com engenharias, mas utilizou *class_weight* como estratégia de balanceamento. Essa junção de uma alta acurácia com um F1-Score menor indica que o Random Forest é um modelo mais conservador, acertos muitos vinhos ruins, mas encontrou menos vinhos bons (51,9%) se comparado ao XGBoost.

Diferente dos modelos baseados em árvores, o SVM é um modelo baseado em distância, obteve o melhor desempenho no cenário com 11 variáveis (features originais) e RobustScaler, utilizando apenas o SMOTE como estratégia de balanceamento. Isso significa que as features de engenharias adicionaram ruídos e não informações para o SVM, sendo sensível a amplitude dos dados. Nesse modelo o RobustScaler foi melhor que StandardScaler, indicando que o modelo se beneficiou da resistência a outliers que o escalador proporciona.

A tabela 2 evidencia que otimizamos cada modelo individualmente, não forçamos todos a usarem as mesmas configurações. Foi deixado cada algoritmo “escolher” sua melhor combinação. Embora o Random Forest apresente a maior acurácia, o XGBoost atingiu o melhor F1-Score (métrica principal). Assim o modelo identificou mais vinhos de alta qualidade (classe minoritária).

A Gráfico 7 apresenta o resultado dos Top 3 modelos em relação aos acertos e erros no conjunto de teste (204 amostras). Nota-se que o Random Forest obteve o melhor número de acertos (187 acertos, correspondendo a 91,7% de acurácia, seguido pelo XGBoost SVM (178 acertos e 87,3% de acurácia).


Gráfico 7: Top 3 melhores modelos – Acertos vs. Erros



Nota: Resultado do conjunto de Teste (204 amostras). A percentagem e acertos é a acurácia.

O gráfico 7 revela uma contradição, o Random Forest tem mais acertos no total que os demais modelos, mas o XGBoost foi escolhido como melhor modelo. Entretanto, analisar apenas olhando para a acurácia (embora intuitiva) pode ser enganosa, principalmente em uma base de dados desbalanceada (apenas 13,5% dos vinhos são de alta qualidade. Para compreender a natureza dos acertos e erros de cada modelo, o Gráfico 8 apresenta matrizes de confusão detalhadas.

Gráfico 8: Matrizes de confusão



Nota: Os valores absolutos estão acompanhados das percentagens por linha.

Ao observar o Gráfico 8, percebe-se que XGBoost encontrou 23 vinhos de alta qualidade (85,2% de Recall) e 155 vinhos de baixa/média qualidade, o Random Forest encontrou apenas 14 (51,9%) de alta qualidade e 173 vinhos de baixo/média qualidade, SVM encontrou 19 vinhos de alta qualidade (70,4%) e 159 vinhos de baixa/média qualidade.

A análise das matrizes revela que o XGBoost encontrou 23 vinhos bons (85,2% de Recall), enquanto o Random Forest encontrou apenas 14 (51,9%). Embora o XGBoost cometa mais falsos positivos (22 vs. 4 do RF), ele erra menos na classe mais importante para o projeto: os vinhos de alta qualidade.

A matriz confusão também nos revela os erros cometidos por cada modelo: XGBoost apresentam 22 falsos positivos (classifico vinhos de baixa/média qualidade como de alta


qualidade) e apenas 4 falsos negativos (deixou passar vinhos de alta qualidade); Random Forest apresentou 4 falsos positivos e 13 falsos negativos; SVM apresentou 18 falsos positivos e 8 negativos. Esse cenário nos leva para o dilema:

- Erro do Tipo I (falso positivo): Quando classifica um vinho comum como um vinho de alta qualidade. A consequência disso seria vender um produto inferior por um preço elevado, prejudicando a confiança dos clientes.
- Erro do Tipo II (falso negativo): Classificar um vinho de alta qualidade como um vinho comum. A consequência desse ato seria descartar, vender ou servir um vinho bom de maneira inadequada, representando uma perda financeira irreversível.

Embora o modelo XGBoost tenha mais erros do tipo I (22 falsos positivos), ele minimiza os erros do tipo II (4 falsos positivos), encontrado cerca de 85,2% os vinhos de alta qualidade. No contexto, se usar esse modelo como um filtro inicial, onde identificar vinhos de alta qualidade para uma análise mais detalhada, esse modelo é mais adequado, esses vinhos considerados de alta qualidade irão passar por uma avaliação sensorial humana (*sommeliers*) antes da comercialização.

O Gráfico 9 apresenta a curva ROC (*Receiver Operating Characteristic*) e a área sob a curva (AUC-ROC) dos modelos.

Gráfico 9: Curva Roc



Nota: A Curva ROC ilustra o trade-off entre a Taxa de Verdadeiros Positivos (Recall) e a Taxa de Falsos Positivos (FPR) em **todos os possíveis thresholds de classificação**. A linha tracejada diagonal representa um classificador aleatório (AUC = 0,500), enquanto o canto superior esquerdo (0,1) representa a zona ideal de classificação perfeita.

Todos os três modelos apresentam um AUC superior a 0,90, isso significa uma excelente capacidade discriminatória entre vinhos de alta qualidade e vinhos de baixa/média qualidade. Um detalhe importante aparece ao comparar o AUC como F1-score, o SVM apresentou o maior AUC (0.908), significa que, em termos de classificação gerais das probabilidades, ele é ligeiramente superior aos demais em relação a classificar as classes. Tanto o XGBosst (0,903) e o Random Forest (0,901), apresentam valores bem próximos.

O fato de o XGBoost ter o melhor F1-Score, significa que suas probabilidades estão calibradas para o *threshold* padrão (0,5), sendo mais eficaz na configuração padrão. Já o SVM, mesmo tendo um AUC ligeiramente melhor, pode se beneficiar de um ajuste de **threshold** para maximizar seu F1-Score.

Destacando a linha roxo escuro, o modelo XGBoost, percebe-se uma suavidade na sua curva na região de alta, demonstrando que ele consegue capturar mais vinhos de alta qualidade sem tanto aumento na taxa de falsos positivos.

Discussão sobre o Trade-off entre os modelos

Como foi discutido anteriormente, escolher o XGBoost ao invés do Random Forest, estamos priorizando o Recall em detrimento da *Precision*. O Recall mede a proporção de verdadeiros positivos identificados pelos modelos em relação ao total de positivos reais. No contexto em que visa identificar mais vinhos de alta qualidade, um Recall de 85,2% (XGBoost) significa que o modelo identificou cerca de 85% dos vinhos de alta qualidade, enquanto o Random Forest teve um Recall de 51,9%, significa que quase metade dos vinhos de alta qualidade foram descartados.

Essa escolha seria uma estratégia de um “filtro inicial” para minimizar os falsos negativos (Erro do Tipo II), aceitando um aumento controlado nos falsos positivos (Erro do Tipo I), que seriam filtrados por especialistas. Assim, seria um filtro inicial para avaliações humanas.

Uma outra estratégia que poderia melhorar ainda mais o XGBoost, seria reduzir o *threshold* de classificação (0,3 ou 0,4), o modelo se tornaria mais sensível, captando ainda mais vinhos bons (aumentando o Recall), mas iria aumentar proporcionalmente os falsos positivos, como esses casos seriam filtrados pelos especialistas na etapa seguinte, é uma configuração viável.

Por causa desse tamanho amostral (204 amostras no conjunto de teste), uma variação de 3 ou 4 vinhos representa uma mudança significativa no Recall. Então, para validar a robustez dos resultados, foi analisado a variabilidade entre os 3 *folds* de validação cruzada, mostrando que o padrão se manteve consistente como pode-se observar na Tabela 3.

Tabela 3: Análise de variabilidade entre as Folds

	F1-Score	Recall	Precision
XGBoost			
Fold 1	0.462	0.587	0.380
Fold 2	0.412	0.444	0.385
Fold 3	0.588	0.761	0.479
Random Forest			
Fold 1	0.456	0.391	0.545
Fold 2	0.400	0.289	0.650
Fold 3	0.578	0.565	0.591

Nota: Apresenta as métricas de desempenho (F1-Score, Recall e Precision) de cada modelo em cada um dos 3 folds da validação cruzada estratificada.

A tabela 3 mostra a robustez e a consistência dos resultados, revelando um padrão consistente, em todos os 3 *folds* o XGBoost apresentou Recall superior ao Random Forest (0,587 vs. 0,391 no *Fold* 1; 0,444 vs. 0,289 no *Fold* 2; 0,761 vs. 0,565 no *Fold* 3). No entanto, o Random Forest apresentou maior *Precision* (0,545 vs. 0,380; 0,650 vs. 0,385; 0,591 vs. 0,479). Assim, o XGBoost é mais eficaz para identificar vinhos de alta qualidade (alto Recall) enquanto o Random Forest é mais conservador em suas previsões (alta *Precision*).

Observa-se que no *Fold 3*, em ambos os modelos apresentam um desempenho melhor se comparado aos *Folds 1 e 2*. Isso é esperado, pois a base de dados é pequena e desbalanceada, onde pode acontecer que os *folds* podem conter proporções ligeiramente diferentes de vinhos de alta qualidade. Mesmo mantendo essa variabilidade, a diferença entre os modelos se manterem estáveis, onde o XGBoost é mais eficaz identificando vinhos de alta qualidade.

No entanto, é importante ressaltar que existe um cenário onde não houvesse *sommeliers* para conferir a qualidade do vinho e filtrar os falsos positivos, ou seja, o modelo é utilizado para a classificação final e automática dos vinhos, o Random Forest se tornaria o melhor modelo, pois o custo de vender um vinho ruim como alta qualidade (falso positivo) seria catastrófico, pois iria perder a reputação da vinícola, os clientes iriam devolver os lotes, causando dano a marca. Assim, o custo de não identificar um vinho de alta qualidade (falso negativo) seria bem menor, o vinho seria vendido como média qualidade, gerando lucro menor, mas sem causar danos à reputação da vinícola.

Neste cenário, o Random Forest apresentando menos falsos positivos (4) e uma alta *Precision* (77,8%), seria superior ao Recall do XGBoost. Portanto, a escolha do modelo vai depender do contexto de uso da estratégia de custos associados a cada tipo de erro.


Importância das variáveis

Para identificar quais variáveis têm maior influência na qualidade do vinho, foram analisadas duas perspectivas diferentes. O Gráfico 10, mostra a correlação de Pearson, apresentando as 11 features originais.

A análise de correlação do Gráfico 10, revela que alcohol apresenta a correlação mais forte com a qualidade (0,49), sugere que a uva foi colhida no ponto certo de maturação (contendo mais açúcar natural), seguida por sulphates (0,26), significa que níveis mais adequados de sulfato preserva os aromas e cor sem afetar o sabor e citric acid (0,24), que contribui para o frescor e equilíbrio gustativo.

No entanto, volatile acidity apresenta forte correlação negativa (0,41), significa que vinhos com maior nível de acidez volátil tem menos qualidade. É um dos principais defeitos, pois pode significar que o vinho foi mal armazenado.

Gráfico 10: Correlação entre as características e qualidade do vinho




Nota: Tons de roxo escuro indicam correlação positiva; tons de roxo claro indicam correlação negativa.

O Gráfico 11 mostra a importância das Features no XGBoost, esse modelo foi escolhido como o melhor algoritmo (supondo que seria como um primeiro “filtro”), concede maior importância a alcohol (0,215), confirmando a correlação do Gráfico 10.

No entanto, o modelo mostra que as variáveis criadas durante o pré-processamento, sulphates_alcohol_product (0,158) e acidity_balance (0,130) tiveram destaque, capturando padrões não-lineares importantes que a correlação linear sozinha não revela.

Gráfico 11: Importância das 14 Features no modelo XGBoost



Esse destaque das duas features criadas terem destaque faz sentido enológico, o acidity_balance seria como um “saldo de qualidade” da acidez, já que é a subtração da acidez volátil (vinagre) e do ácido cítrico (frescor). Já o sulphates_alcohol_product, captura a ligação não-linear entre o corpo do vinho (álcool) e sua estabilidade/conservação (sulfatos), implicando que ambos estejam em níveis mais adequados para que um vinho seja qualificado como de alta qualidade.

Esse resultado mostra que a qualidade do vinho não depende apenas de fatores isolados, mas de interações mais complexas entre eles, mesmo não apresentando uma correlação tão alta. Em suma, as variáveis com maior influência para a qualidade do vinho são:

- **alcohol:** Importante tanto na correlação quando no modelo;
- **volatile acidity:** Forte correlação negativa, e foi capturada indiretamente pelas novas features;
- **sulphates:** Correlação positiva e importância no modelo (0,046), e sendo capturada pela nova feature criada (sulphates_alcohol_product).

Implicações para o processo de produção:

Na prática, a vinícola pode usar o modelo XGBoost como um *filtro inicial*, os vinhos que são classificados como ‘bons’ seriam encaminhados para a mesa de prova dos especialistas, enquanto os vinhos classificados como baixo/médio seguiriam para o processo de descarte ou venda por preços menores. Essa ferramenta de triagem inicial, apresenta 3 benefícios operacionais:

- **Redução de custo e tempo:** com um Recall de 85,2%, o modelo prever a grande maioria dos vinhos de alta qualidade, facilitando para os especialistas, fazendo com que foquem seu tempo nas amostras pré-selecionadas pelo modelo. Isso reduziria significante o número de degustação necessária e otimizaria a mão de obra especializada.
- **Padronização de Qualidade:** o modelo utiliza critérios objetivos e consistentes baseados nas variáveis físico-químicas, garantindo o padrão produtivo entre diferentes safras de vinhos, diferente da avaliação dos especialistas (sensorial humana), que são sujeitas a variações do paladar, subjetividade e fadiga dos *sommeliers*.

Capacidade de expansão: o modelo consegue avaliar centenas de amostras por segundos, isso permite um controle maior de qualidade durante o processo de vinificação, não somente na produção final.

O modelo oferece também, valiosos insights para o processo produtivo, mostrando a importância de alguns componentes físico-químicos (álcool e acidez volátil), mostrando o que a vinícola deve priorizar. Como por exemplo, o controle de fermentação para atingir o teor alcoólico adequado; prevenção de contaminação, mantendo a acidez volátil em níveis baixos; e adição controlada de sulfatos, para garantir o sabor.

Vale ressaltar que a implementação de um modelo de Machine learning (aprendizado de máquina) não requer investimentos adicionais em análises laboratoriais. Pois, as 11 variáveis físico-químicas essenciais para o modelo, são medidas por vinícolas de médio e grande porte, fazendo parte do controle de qualidade obrigatório antes do engarrafamento.

Portanto, o modelo apenas aproveita dados que já estão sendo coletados para extrair percepções adicionais, sem um custo operacional significativo. As vinícolas teriam que implementar a integração desses dados em um sistema de predição, sendo automatizado por planilhas. Entretanto, não seria viável para vinícolas pequenas artesanais que não teriam seu próprio laboratório, pois teriam custos terceirizados para essa análise.

É importante ressaltar que esses modelos não substituem a avaliação sensorial humana, apenas a complementam. Pois, aspectos como harmonização, aroma e preferências, precisam das experiências dos especialistas.

Conclusão

O projeto revelou que é possível prever a qualidade de um vinho com base em características físico-químicas utilizando modelos de Machine learning. O modelo XGBoost, configurado com o cenário de 14 variáveis (com *feature engineering*), escalonado com StandardScaler e utilizando a estratégia de balanceamento SMOTE + *class_weight*, alcançando um F1-Score de 0,639 e AUC-ROC de 0,903.

A análise exploratória e a importância das variáveis evidenciaram que o teor alcoólico (alcohol) e a acidez volátil (volatile_acidity) são as maiores características físico-químicas para determinar a qualidade, esse resultado está em total concordância com os princípios da enologia. Além disso, os *feature engineering* apresentaram eficiência: as variáveis criadas como sulphates_alcohol_product e acidity_balance, apareceram entre as mais importantes para o modelo. Portanto, a qualidade do vinho não depende apenas de fatores isolados, mas das interações complexas entre seus componentes.

É importante ressaltar algumas informações metodológicas. O *dataset* utilizado é relativamente pequeno (1.143 amostras²) e apresenta um desbalanceamento significativo (apenas 13,5% dos vinhos são de alta qualidade), o que introduz uma incerteza estatística, principalmente no conjunto de teste apenas 27 vinhos da classe minoritária (14% das 204 amostras). É importante destacar que a ‘qualidade’ do vinho, é uma métrica baseada em avaliações humanas, o que impõe um limite natural à precisão de qualquer modelo.

Sugere-se a aplicação desses modelos em bases maiores e mais recentes para validar a robustez dos resultados. Uma expansão seria um ajuste do *Threshold* de decisão, reduzindo para 0,3 por exemplo.

Em suma, o modelo XGBoost provou que é uma ferramenta viável de custo zero (pois os as variáveis físico-químico já estão disponíveis) para atuar como um filtro inicial em vinícolas, otimizando o tempo dos especialistas e padronizando o controle de qualidade.

² O *dataset* apresentava 1.143 amostras antes de remover as duplicatas, depois da remoção vai para 1.018.

Referencias

CORTEZ, P.; CERDEIRA, A.; ALMEIDA, F.; MATOS, T.; REIS, J. Modeling wine preferences by data mining from physicochemical properties. **Decision Support Systems**, v. 47, n. 4, p. 547-553, 2009. Disponível em: <https://doi.org/10.1016/j.dss.2009.05.006>. Acesso em: 31 mai. 2026.

HASSAN, Y. **Wine Quality Prediction**. Kaggle, 2022. Disponível em: <https://www.kaggle.com/datasets/yasserh/wine-quality-dataset>. Acesso em: 31 mai. 2026.